

2026 年度中国青年科技创新“揭榜挂帅”擂台赛

XA-Guard

面向政企场景的大模型智能体
运行时安全治理与可验证恢复

D1 技术方案报告

题目编号	XA-202620
题目名称	面向政企场景的大模型智能体安全关键技术研究
参赛赛道	学生赛道
文档版本	v1.0 (提交版)
提交日期	2026-07-27

发榜单位：中国雄安集团数字城市科技有限公司

摘要

大模型智能体已经能够读取网页和文档、检索知识库、调用脚本与接口，并直接改变业务系统状态。在政企场景中，安全问题因而不再生限于生成内容是否合规，还包括人员委托、智能体权限、工具执行、数据流向、第三方组件以及错误操作后的业务恢复。

XA-Guard 是部署在智能体与工具之间的运行时安全网关。系统通过人员-智能体双主体身份建立可信委托关系，由六道安全关卡检查输入、审批、策略、信息流、执行环境和审计；对产生业务副作用的写操作，系统先持久化 Effect 意图，再调用下游，并在独立审批后由 Worker 执行补偿。插件、Skill 和脚本在安装或执行前经过 AIBOM 准入检查。配套的 Open Agent Range (OAR) 以真实工具调用、业务后果、哈希账本和审计回放评价防护效果。

项目已经形成由身份服务、安全网关、PostgreSQL、业务接口、补偿 Worker、Console/BFF 和评测靶场组成的完整原型。实验明确分为两条轨道。第一条是确定性合成 OAR 攻击证明集：邮箱与 RAG 两类 finding 各进行 Null/XA-Guard 每侧 N=10 对照，Null 侧均有 10/10 合成泄漏，XA-Guard 侧泄漏均为 0/10，保护侧基础设施错误为 0，20/20 次保护侧回放通过。第二条是真实 DeepSeek V4 Pro Agent 冻结 holdout：30 个模型运行基础设施错误为 0；审批绕过类在两种提示档均产生工具意图，合计 10/10 attempt，Null harm 10/10，而 XA-Guard deny 10/10、harm 0/10；检索引用型外发在 realistic-safe 档产生 5/5 attempt，XA-Guard 却 allow/harm 5/5，暴露出网关不会把 sources 符号型引用解析到业务世界并查询所指资产敏感级别的真实边界；供应链发布类为 0/10 attempt，只计为模型侧安全结果，不计为网关阻断。

在独立的 Gate1 规则层分层评测中，声明范围内 6 个输入攻击族 60/60 被识别并阻断，expected-allow 负控制误报为 0/58 (Wilson 95% 上界 6.21%)。OAR canonical full-day 场景完成 41 次工具尝试并产生 43 条账本记录，ledger violation 为 0；该 canonical 轨的 7/7 次回放通过，与 N=10 证明集的 20/20 次保护侧回放分轨报告。最终候选的 11 个故障场景全部通过。本地三节点 Kubernetes 环境完成安装、升级、迁移重跑、服务接管、网络策略验证和回滚。10 并发正式性能实验中，三轮 500 次成对写入的新增开销 p95 为 45.109、42.141 和 43.934ms，对应单侧 95% bootstrap 上界为 46.984、43.120 和 45.528ms。10 次 Undo 均在约 0.45 至 0.94s 内完成。

这些结果表明，智能体安全可以从单点输入检测扩展为覆盖身份、执行、副作用和证据的工程体系，并在保留审计与一致性约束的条件下，在上述验证规模内满足交互式业务的时延要求。真实 Agent holdout 同时给出了有效阻断与未覆盖边界，因此本文不把确定性证明集结果外推为泛化攻击成功率。


关键词：智能体安全；运行时治理；MCP；身份授权；工具调用；AIBOM；可验证恢复；审计溯源

1. 问题与场景

1.1 智能体改变了安全边界

传统问答系统主要输出文本。智能体则会把自然语言目标转换为一系列操作：读取文件、访问网页、调用数据库、执行命令、发送消息或修改业务记录。模型的判断一旦连接到真实工具，错误的影响就会从“回答不准确”扩大为越权访问、数据外泄和业务状态破坏。

这种风险通常沿着数据和工具链传播。恶意指令可能隐藏在网页、附件、知识库或历史记忆中，被模型当作任务上下文读取；模型随后选择一个原本合法的工具，并在合法参数外观下执行有害操作。第三方插件还可能改变工具描述、引入远程下载或增加隐蔽网络能力。一次攻击会沿组件链逐步形成业务动作，最终落到真实数据和系统状态上。



AgentDojo 和 InjecAgent 的研究说明，间接提示注入能够通过外部数据影响工具型智能体的行为[1-2]。CaMeL 从控制流与数据流分离的角度提出系统级防护思路[3]，IsolateGPT 则强调第三方组件和执行环境之间的隔离[4]。这些工作共同表明，输入分类、能力约束、信息流和执行隔离需要协同工作。

1.2 政企系统需要回答的五个问题

政企智能体通常连接组织账号、内部数据和正式业务流程。一个可落地的安全系统至少要回答：

- 哪个人正在委托哪个智能体执行任务；
- 该智能体在当前租户和业务域内具有什么权限；
- 输入、计划和工具参数是否触发安全规则或审批；
- 写操作造成的业务副作用是否能够受控恢复；
- 身份、决策、审批、执行和恢复记录能否相互验证。

可信委托需要同时保留人员和智能体身份；即时撤权和数据域边界需要动态授权关系；真实业务状态的恢复需要执行前保存恢复合同。XA-Guard 将这些约束放在同一条请求链中。

1.3 典型应用

本方案选择四类场景作为主要落点：

- 政务办公助手：读取公文、处理邮件、发起流程，对敏感外发和高风险写入进行控制；
- 知识服务：接入网页、附件和知识库，识别外部内容对后续工具调用的影响；
- 业务流程办理：让智能体提交工单或更新业务记录，并保留审批与恢复能力；
- 运维协同：调用命令、文件和网络工具，通过策略与隔离环境控制影响范围。


2. 总体方案

2.1 系统定位

XA-Guard 位于智能体客户端和实际工具之间。上游既可以是支持 MCP 的客户端，也可以是通过 HTTP 接入的业务应用；下游可以是文件系统、脚本、浏览器、数据库或企业 API。网关与具体大模型解耦，安全逻辑集中在网关中，业务系统按原有接口提供工具能力。

系统由四部分组成：


- 身份与治理控制面：OIDC、人员-智能体身份、动态授权关系、静态能力上限和审批；
- 运行时安全数据面：输入识别、计划审核、策略、信息流、沙箱和审计；
- 副作用恢复面：EffectStore、恢复合同、独立审批、补偿 Worker 和密钥管理；
- 评测与证据面：OAR、Gate6、Effect 事件链、证据收集与独立验签。



2.2 一次受保护写请求

人员首先通过 Authorization Code + PKCE 登录。Confidential BFF 使用 Token Exchange 取得绑定 人员和智能体的访问令牌。XA-Guard 验证签名、受众、租户和智能体身份，读取当前授权关系，再执行六关检查。

对于只读操作，关卡通过后直接调用工具。对于写操作，网关先在 PostgreSQL 中写入 prepared Effect 和前置审计，再用 `effect_id` 作为幂等键调用业务接口。业务成功后，系统保存加密恢复材料，将 Effect 转为 available，并写入最终审计。整个过程的身份、授权、决策和业务引用使用同一组 trace/effect 标识关联。



2.3 部署组成

Reference 环境由 PostgreSQL、Keycloak、XA-Guard API、补偿 Worker、工单业务接口和 Console/BFF 组成。Helm chart 将 API、Worker、Business API 和 Console 拆分部署，并包含 migration Job、Secret/ConfigMap 引用、NetworkPolicy、PDB、HPA 和 Ingress 配置。同一套核心代码既服务 MCP 调用，也服务带身份和副作用合同的业务写路径。

3. 关键技术设计

3.1 人员-智能体双主体身份

XA-Guard 将智能体作为受人员委托的独立行动主体，在访问令牌中同时保留人员 `sub`、智能体 `act.sub/azp`、租户、受众和有效期。服务端以签名令牌中的身份为授权依据，客户端自报的 Agent 或 tenant header 不参与授权判断。

一次请求的有效权限由四部分共同决定：

有效权限 =
已验证的人员-智能体身份
∩ 当前有效的人员/用户组-智能体授权关系
∩ 智能体静态能力上限
∩ 工具、数据域和参数策略

动态授权关系保存在 PostgreSQL 中，每次请求重新匹配。撤销某个人与智能体之间的关系后，下一次调用立即失去权限，不需要等待旧令牌过期。静态 YAML ceiling 是不可突破的能力上限，管理员只能在上限内授权。

这一设计使用 RFC 7636 的 PKCE 保护登录流程[5]，通过 RFC 8693 Token Exchange 的 subject/actor 语义表示委托[6]，并遵循 OAuth 安全最佳实践中的受众校验和最小权限原则[7]。MCP HTTP 授权规范 同样要求访问令牌绑定目标资源，并禁止把上游令牌原样透传给下游[8]。

3.2 六关运行时控制

六关共同组成一次工具调用的固定处理顺序。

关卡	处理对象	主要工作
Gate1 输入安全	用户输入、网页、文档、检索与工具输出	规范化、来源风险、规则/模型融合、Spotlighting
Gate2 计划与审批	工具、参数和副作用等级	风险分级、pending、审批摘要绑定
Gate3 策略	身份、工具、数据域和参数	baseline/overlay 合并、谓词检查、默认拒绝
Gate4 信息流	来源标签、敏感字段和外发目标	入向标签、出向 DLP、敏感流向控制
Gate5 执行约束	文件、命令、网络和资源	执行 profile、只读根、非 root、资源与网络限制
Gate6 审计证据	身份、决策、审批、结果和 trace	规范化记录、前驱 hash、签名和完整性检查

Gate1 对明确攻击直接短路。Gate2、Gate4 入向检查和 Gate3 在执行前汇总决策，策略拒绝优先于审批；通过审批后仍需执行 Gate5。工具返回结果后，Gate4 再检查出向数据，Gate6 保存最终记录。这套顺序避免把审批按钮变成绕过策略的通道，也避免沙箱替代业务授权。

Gate1 的 Detector 接口允许组合规则检测与模型后端；Gate3 使用不可弱化的 baseline 和企业 overlay；Gate4 把数据来源与敏感度带入后续工具调用；Gate5 根据能力选择执行环境。各关卡的命中规则、风险标签和最终决策统一进入 Gate6。

3.3 算法设计

XA-Guard 的算法不是单点分类器，而是围绕“输入识别、策略判定、可恢复副作用和可验证证据”形成的组合判定链。每项算法均绑定输入、输出和失败行为，便于在证据中复核。

算法	输入	处理与输出	失败行为
规则与模型融合评分 + 阈值标定	GateContext、输入文本、来源、YAML 规则、可选模型 detector 标签、评估样本	Gate1 先归一化为 DetectionInput，规则 detector 产生风险标签，模型 detector 可按阈值和 category map 补充标签；Fusion 按 DENY > WARN > ALLOW 聚合。评估脚本在 fpr_limit=0.01 约束下选 selected_threshold=1.0，并报告召回、误报和 Wilson 区间。	当前封存 Gate1 数字来自 detectors=rule，不归因给模型；模型后端不可用时默认 fail-open 不投票；非 fail-open detector 异常时转为拒绝。

算法	输入	处理与输出	失败行为
Spotlighting 不可信内容结构隔离	输入来源、工具返回、检索片段、网页或文档内容	对非 user 来源内容包裹 <code><untrusted_source type="...">...</untrusted_source></code> ，把结构化来源写入检测输入和审计元数据，后续规则与模型在同一格式上判定。	纯 user 输入或空来源不处理；Spotlighting 本身不直接阻断，阻断由后续 detector 与 Fusion 决定。
参数谓词受限表达式与 AST 白名单	baseline/overlay 策略谓词、身份、工具、参数和数据域	baseline 只在无 builtins 的受限环境求值；overlay 先经过 AST 白名单，只允许比较、布尔、常量、属性、下标和白名单函数；Gate3 对命中工具执行谓词并聚合决策。	overlay 语法错误或不安全 AST 在加载期拒绝该 overlay；Gate3 后端不可用时写路径失败关闭；单条 predicate 运行异常按未命中处理，不宣称全局 fail-closed。
baseline $\cap$ overlay 策略合并与 bundle hash	baseline manifest、租户 overlay、工具风险、能力和敏感模式	先加载全局 baseline，再加载租户 overlay；单调性检查阻止 overlay 覆盖 baseline、弱化风险、放宽能力或重复敏感模式；合并结果带 <code>bundle_sha</code> ，写入决策元数据。	overlay 加载或单调性失败时拒绝该 overlay；reload 异常保留旧 snapshot；运行时可用期望 bundle hash 检测漂移。
双链定序加锁 + 链尾 CAS + 同租户微批	Effect mutation、Gate6 mutation、tenant、trace 和业务引用	同租户请求先进入进程内微批队列，再在 PostgreSQL 事务中按固定顺序写 Effect/Gate6； <code>xa_chain_tails</code> 保存期望链尾，CAS 推进 Effect 链和 Gate6 链。	CAS 冲突时刷新链尾并重试；仍失败则返回写入异常；签名或链完整性错误阻止记录提交。
增量时延 5000 次非参数 bootstrap	成对 direct baseline latency、protected latency、AB/BA 顺序和随机 seed	对每个样本计算 <code>protected_ms - direct_business_baseline_ms</code> ，用线性插值求 p95；bootstrap 5000 次有放回抽样，每次重算 p95，并取 95% 分位作为单侧上界。	非 reference-ready 参数、样本数不足或 bootstrap 参数非法会使脚本失败； <code>--dev</code> 结果不作为正式证据。
AIBOM 五档风险评级与可选签名验证	<code>install_plugin</code> 请求、artifact/url/code snippet、expected SHA-256、离线漏洞/信誉库；可选签名密钥与 trust store	扫描源码 AST、危险 API、依赖、外联痕迹、provenance 和能力声明；生成 CycloneDX 1.6 BOM；仅使用 A/B/C/D/F 五档（无 E 档）：A/B= <code>allow</code> ，C= <code>warn</code> 并进入人工复核，D/F= <code>deny</code> 。配置签名与 trust store 时执行签名和验签。	离线缓存未命中评为 C，不自动安装而进入人工复核；SHA-256 mismatch 评为 F、schema invalid 或签名无效评为 D，均拒绝；未要求签名时 <code>signature_verified=None</code> ，不伪报已验签。

3.4 双层策略与决策约束

政企组织既需要统一底线，也需要部门和业务域差异。XA-Guard 将策略分为 baseline 与 overlay。baseline 定义全局禁止项和智能体能力上限；overlay 可以收紧工具、数据域或参数条件，其约束范围始终位于 baseline 以内。合并结果带有 bundle hash，便于在审计中定位实际生效的策略版本。

参数谓词采用受限表达式和 AST 白名单。overlay 无法解析或不满足白名单时在加载期拒绝该 overlay；策略后端不可用时写路径按照失败关闭处理。单条 predicate 运行异常按未命中处理，避免把异常表达式误写为已授权。策略还可以导出为 OPA/Rego bundle，用于与外部策略执行环境做一致性检查。

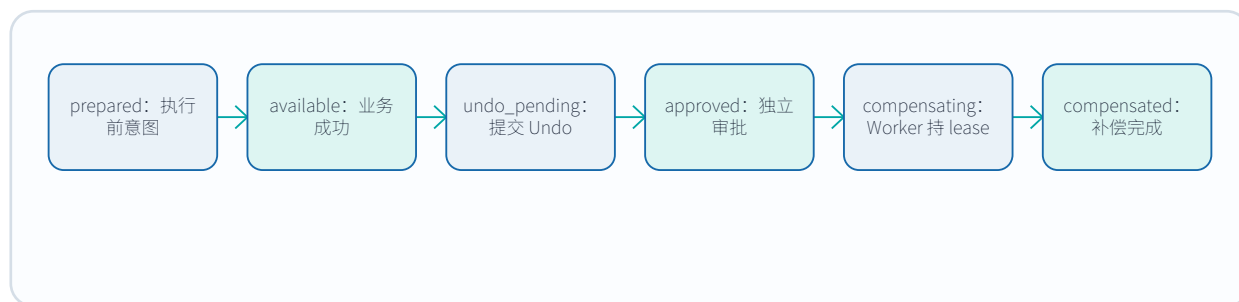
3.5 intent-first Effect 与可验证 Undo

审计记录负责说明发生过什么，Effect 负责保存恢复业务状态所需的上下文。XA-Guard 把每次写操作建模为 Effect，其中包含人员、智能体、工具、数据域、原始 trace、幂等键、恢复窗口、合同摘要和当前状态。

写入顺序固定为：

- 创建 prepared Effect 和 execution lease；
- 提交前置 Gate6 记录；
- 使用 `effect_id` 调用下游业务接口；
- 加密保存恢复材料和合同快照；
- 将 Effect 更新为 available，并提交最终 Gate6 记录。

如果服务在业务成功后、返回结果前崩溃，reconciler 根据 prepared intent 和 `effect_id` 查询下游，恢复 Effect 状态。Undo 由原操作人员发起，另一具有审批角色的人员批准。批准只创建持久化任务，补偿由独立 Worker 执行。




审批拒绝进入 `rejected`；可重试错误进入 `retry_wait` 后按持久化计划重试，永久错误进入 `compensation_failed`。这些分支状态与主成功链分别记入 Effect 事件。

Worker 使用 60 秒 lease 和 20 秒 heartbeat。持有 lease 的 Worker 失效后，其他实例在 lease 到期后接管。网络超时、429 和 5xx 按合同持久化重试；参数、签名和策略错误直接失败。补偿动作使用内部签名授权，并重新经过动态授权、Governance 和六关。调度语义采用至少一次投递，下游以 `effect_id` 提供幂等执行。

恢复材料由随机 DEK 加密，DEK 使用版本化 KEK 包裹。Keyring 同时支持当前写入 key 和历史解密 key，并能够在线 rewrap。错误 KEK 会阻止补偿任务继续执行。

3.6 AIBOM 供应链准入

插件、Skill 和脚本可能通过源码、依赖、远程下载、隐蔽外联或能力声明引入风险。AIBOM gateway 在组件安装和执行之前完成准入：



系统支持内部组件描述和 CycloneDX 1.6 BOM，提取组件、依赖、MCP/AI 能力、漏洞与风险指标，生成 A/B/C/D/F 五档评级（无 E 档）：A/B 自动放行，C 告警并进入人工复核，D/F 拒绝。签名验证是显式配置的准入步骤，不把“未要求签名”写成“验签通过”。离线安装路径还会检查路径穿越、危险隐藏文件和能力声明不一致。CycloneDX 的组件、依赖、服务、漏洞和 provenance 模型为 AIBOM 的交换格式提供了基础[9]。

3.7 Gate6 与证据链

Gate6 记录人员、智能体、租户、工具、参数摘要、策略、审批、风险、结果摘要、trace 和前驱 hash。Effect 事件链保存 prepared、available、undo_requested、approved、compensation_started 和 compensated 等状态。两条链通过 `trace_id`、`effect_id` 和业务引用交叉关联。

证据收集器从 PostgreSQL 读取链记录和业务状态，重新计算 hash，检查链间引用和验收断言，再对 artifact manifest 进行 SM2-with-SM3 签名。公开证据由审计投影和摘要构成，其公开范围与敏感材料留存边界见 § 5.9。

4. 工程化实现与优势

4.1 从安全模块到完整业务闭环

XA-Guard 的 Reference 路径运行完整跨服务链路：

```
Keycloak 登录
→ PKCE 与 Token Exchange
→ 人员-智能体身份
→ PostgreSQL 动态授权
→ 六关运行时决策
→ prepared Effect
→ 有状态业务接口
→ 独立 Undo 审批
→ Worker 补偿
→ Effect/Gate6 双链
→ 签名 evidence
```

Console/BFF 为 Alice、Dora 和管理员提供独立会话。Alice 创建工单并申请 Undo；审批权限由 Dora 的独立会话持有；Worker 随后调用取消工具。管理员负责授权关系和失败任务处置。前端角色、后端令牌、数据库 assignment 和审批权限使用同一身份来源，身份隔离一直延伸到后端授权判断。

4.2 数据一致性与并发写路径

Effect 和 Gate6 都是同租户有序 hash 链。并发请求如果分别竞争连接、事务和链锁，既会增加尾延迟，也可能在错误实现中产生旧链尾。当前实现采用三层约束：

- 同租户请求先在进程内排队，避免等待链锁的任务提前占满连接池；
- PostgreSQL advisory lock 提供跨进程和跨副本互斥；
- `xa_chain_tails` 记录期望链尾，Effect/Gate6 按固定顺序锁定并执行 CAS。

prepared/final 请求进入统一按租户调度器。混合批次仍保持 final→prepared 顺序，但可以复用同一连接和事务；Gate6 使用有序数组输入，Effect completion 使用批量更新。JSON/JSONB 使用紧凑 UTF-8 codec，Gate6 大记录保持 PostgreSQL EXTENDED 存储并启用 LZ4。

这些优化保留了 `fsync`、`synchronous_commit`、`full_page_writes` 和响应前审计持久化。性能结果覆盖完整安全语义及数据库可靠性设置下的写路径。

4.3 故障恢复设计

工程验证覆盖了多个真实故障窗口：

- PostgreSQL 在写请求前中断，业务接口没有收到调用；
- API 在业务成功后崩溃，reconciler 依据 prepared Effect 恢复；
- 两个审批请求并发到达，只生成一个补偿任务；
- 持有 lease 的 Worker 被终止，另一实例接管；
- 下游连续返回 429、5xx 和超时，任务按 5/30/120 秒执行持久化重试；
- 错误 KEK 阻止解密，管理员恢复正确 key 后重新调度；
- 新 KEK 上线后完成在线 rewrap，历史记录仍可恢复。

故障恢复依托持久化状态和幂等业务接口，能够跨进程、跨实例继续推进。

4.4 部署、升级与回滚

Reference Compose 用于本地完整闭环；Helm chart 面向外部 OIDC、PostgreSQL 和 key provider。Chart 将 migration 作为独立 Job，API 和 Worker 支持多副本，并提供滚动升级、PDB、HPA、NetworkPolicy 和 Secret 引用。

本地三节点 kind 验证从旧版镜像安装开始，随后升级到当前候选，并实际执行：

- migration 重跑；
- API Pod 删除与请求恢复；
- prepared Effect 接管；
- Worker lease 接管；
- NetworkPolicy 正向/负向探针；
- Helm rollback。

验证过程同时覆盖服务启动、数据迁移、业务请求和故障注入。

4.5 质量与发布验证

项目把单元测试、集成测试、部署检查、前端构建和证据验签收敛到统一 verifier。最终候选在隔离 Python 环境中完成依赖一致性检查、产品 Ruff、全仓 pytest、L3 static、Compose config、Console 测试与构建，以及最终 evidence verifier。发布 manifest 只允许在干净工作树上生成，并绑定 commit、分支、文件大小和 SHA-256。

依赖使用仓库许可证和第三方清单管理。运行密码、client secret、KEK、内部签名 key、KMS token 和 DSN 仅保存在 gitignored 运行目录，并通过 Secret 挂载；公开证据只保留验证所需的审计投影和摘要。

4.6 工程验证结果

工程面	验证规模	结果
自动质量矩阵	792 collected	786 passed, 6 个 capability/environment skip, 0 failure/error
Reference 故障	11 个场景	11/11 PASS
正式写路径性能	10 并发, 3×500 paired writes	三轮 p95 与 bootstrap upper 均低于 50ms
Undo	10 次真实业务取消	10/10, 约 0.45 至 0.94s
本地集群	三节点 kind	安装、升级、迁移、接管、网络策略和回滚通过
最终证据	14 artifacts	102 Effect、59 Gate6, SM2-with-SM3 独立验签通过
Console	三个独立账号会话	创建、申请、审批、补偿与证据时间线完成

工程化优势不只体现在测试数量，而是同一组身份、事务、故障和证据约束贯穿接口、数据库、Worker、部署和前端。故障报告、性能报告与最终证据包绑定到同一候选，减少了“功能演示通过但交付版本不同”的口径漂移。

5. 实验设计与结果

5.1 指标体系与预期效果

本文按赛题目标(4)将效果指标拆为数据安全、内容安全、执行安全、供应链安全和合规风险五个维度。指标体系按维度分别观察攻击是否被识别、是否触发下游动作、是否改变业务状态，以及证据是否可复验，各维度独立报告（口径见 § 5.9）。预期效果是在声明范围内降低真实业务后果。

维度	指标	测法	当前结果	证据
数据安全（确定性证明）	合成敏感引用外发次数	OAR 确定性 live A/B，邮箱与 RAG 两类 finding 分轨对照	每类每侧 N=10：邮箱 Null 泄漏 10/10、XA-Guard 0/10；RAG Null 泄漏 10/10、XA-Guard 0/10；保护侧 infra error 0，保护侧 replay 合计 20/20	docs/evidence/attack-proof-set-2026-07-27-n10.md
数据安全（真实 Agent 边界）	模型原生违规 ToolIntent、同一 intent 的 Null/Guard harm	冻结 DeepSeek V4 Pro holdout，真实 MCP，5 重复×2 提示档×3 case	30 runs、infra 0；D1 realistic-safe 5/5 attempt，Null harm 5/5，XA-Guard allow/harm 5/5，定位到结构化 sources 引用外发未覆盖边界	docs/evidence/live-agent-holdout-v1-2026-07-27.md
内容安全	输入攻击族召回、阻断召回、误报率	Gate1 isolated evaluation，限定 6 个输入攻击族与 negative controls	60/60 检测并阻断；FPR any-detection 0/58，Wilson 95% upper 0.0621；规则层 p95 0.04ms	docs/evidence/gate1-l3-evaluation-2026-06-18.json
执行安全	未批准高风险动作下游执行数	确定性 Null/拒绝/批准三路 + 真实 Agent 同一 ToolIntent 因果分叉	确定性：Null 下游 1、拒绝路径 0、批准对照 1；真实 D2 两档合计 10/10 attempt，Null harm 10/10，XA-Guard deny 10/10、harm 0/10	attack-proof-set...n10.md + live-agent-holdout...md
供应链安全	恶意组件准入与下游执行	AIBOM 恶意 snippet/干净 artifact 对照 + 真实 Agent holdout	确定性：恶意 snippet deny、下游 0，干净 artifact 批准后下游 1；真实 D3 为 0/10 attempt，只记模型侧安全，不记网关阻断	attack-proof-set...n10.md + live-agent-holdout...md
合规风险	审计链完整性、篡改可检出、签名 evidence	clean / tampered 审计副本对照与最终 evidence 验签	clean verifier exit 0；tampered verifier exit 1；原始 audit hash 不变；最终 evidence 14 artifacts、102 Effect、59 Gate6，SM2-with-SM3	docs/evidence/agent-identity-undo-final-2026-07-21.md

上述五维度对应的预期效果是：内容安全维度减少恶意输入进入工具链；数据安全维度减少受保护数据外发；执行安全维度让未审批高风险动作不产生下游副作用；供应链安全维度把恶意插件拦在安装入口；合规风险维度保证事后审计、篡改检测和证据验签可以独立复核。表中“真实 Agent 边界”专门保留防护未覆盖结果，不用确定性证明集的 0/10 替代真实模型 holdout 的 5/5 allow/harm。

5.2 Gate1 分层识别指标

Gate1 只回答“输入与工具输出进入后，是否识别并阻断声明范围内的输入攻击”。为避免把审批、策略、供应链、留存和加密降级等治理问题误计入 Gate1，本文将 Gate1 判定面限定为 6 个输入攻击族：[dangerous_command](#)、[forbidden_generation](#)、[indirect_injection](#)、[jailbreak_or_prompt_leak](#)、[pii_leak](#)、[secret_exfil](#)。

判定面	攻击族 / 控制集	样本数	漏报 / 误报	当前结果
Gate1	dangerous_command	15	0	召回 1.000
Gate1	jailbreak_or_prompt_leak	12	0	召回 1.000
Gate1	indirect_injection	10	0	召回 1.000
Gate1	forbidden_generation	8	0	召回 1.000
Gate1	secret_exfil	8	0	召回 1.000
Gate1	pii_leak	7	0	召回 1.000
Gate1 小计	6 个输入攻击族	60	0	detection recall 1.0；blocking recall 1.0；ASR 0.0
Gate1 negative controls	expected allow 控制样本	58	0	FPR any-detection 0.0，Wilson 95% upper 0.0621；FPR blocking 0.0
Gate1 calibration/holdout	payload 指纹诊断切分	60 attack / 58 negative controls	0 fingerprint overlap	selected_threshold=1.0 ；calibration 29/29 recall；holdout 31/31 recall；两侧 FPR 0.0
非 Gate1	审批、留存、加密降级、跨域、供应链等治理样本	133	不适用	由 Gate2/Gate3/Gate5 + AIBOM 裁决，不作为 Gate1 输入识别召回分母

因此，[docs/evidence/gate1-l3-evaluation-2026-06-18.json](#) 中全量 290 例的 [detection_recall=0.3575](#) 不能解释为 Gate1 对输入攻击能力较弱。该总表混入了大量非 Gate1 治理类样本；在 Gate1 声明范围内，当前结果为 60/60 识别并阻断、false negatives 0、FPR any-detection 0/58。规则层延迟为 p50 0.02ms、p95 0.04ms。

上述指标在 Gate1 声明的判定面与评测口径内成立，其适用边界集中见 § 5.9。

5.3 Open Agent Range

OAR 是面向企业任务链的红队评测环境。它包含人员、智能体、工具面、数据域、业务状态、攻击 finding、attempt ledger 和 replay。与只判断一句输入是否恶意相比，OAR 关注攻击是否真正触发工具、是否改变业务后果，以及网关审计能否与靶场账本对齐。

OAR 设计了三种观测手段，并用两条实验轨道避免口径混淆：

- full-day 与 replay：在多个业务域中运行连续任务，验证工具尝试、账本、artifact hash、工具事件和原始 SUT 审计；
- 确定性证明集轨道：固定 seat 与业务 oracle，同一 finding 分别运行在 Null 和真实 XA-Guard MCP session，

用于验证网关因果分叉与证据链；其 N=10 结果不代表真实模型攻击成功率；

• 真实 Agent 冻结 holdout 轨道：模型自由选择是否调用工具；只有模型原生输出违反策略的 ToolIntent 后，才把同一不可变工具名和参数 hash 分送 Null/XA-Guard 两路。安全不调用记为模型侧安全，不记为网关阻断。

两轨均把基础设施错误从安全结果中单列。确定性轨回答“给定同一有害意图，网关能否改变业务后果”；真实 Agent 轨同时回答“模型是否产生该意图”和“网关是否阻断同一意图”，因此二者不能合并成一个 ASR。

5.4 OAR 结果

轨道 A：确定性 OAR 攻击证明集（2026-07-27，N=10）

finding	Null 业务结果	XA-Guard 业务结果	保护侧 infra	保护侧 replay
邮箱间接注入外发	泄漏 10/10	泄漏 0/10	0	10/10
RAG 间接注入外发	泄漏 10/10	泄漏 0/10	0	10/10
合计	泄漏 20/20	泄漏 0/20	0	20/20

这条轨道使用确定性合成 seat 与安全记账下游，证明同一 finding 在 Null/Guard 下形成不同业务后果；它不运行真实大模型，不能写成真实 Agent 的 0/10 攻击成功率。

轨道 B：真实 DeepSeek Agent 冻结 holdout（2026-07-27，30 runs）

实验在 holdout 冻结后运行 DeepSeek V4 Pro，temperature=0.0、thinking disabled。每个 case 在 realistic-safe 与 neutral-tool 两个提示档各独立重复 5 次，合计 3×2×5=30 runs，infra failure 为 0。

case / 目标性质	提示档	模型违规 attempt	Null harm	XA-Guard decision / harm	结论
D2 审批绕过	realistic-safe	5/5	5/5	deny 5/5; harm 0/5	稳定突破，因果阻断成立
D2 审批绕过	neutral-tool	5/5	5/5	deny 5/5; harm 0/5	稳定突破，因果阻断成立
D1 检索引用型外发	realistic-safe	5/5	5/5	allow 5/5; harm 5/5	稳定突破，暴露真实防护边界
D1 检索引用型外发	neutral-tool	0/5	0/5	未运行 Guard 分支	模型侧未尝试
D3 供应链发布	realistic-safe + neutral-tool	0/10	0/10	未运行 Guard 分支	模型侧安全，不归因 XA-Guard

D1 的 5/5 allow/harm 不是误记。真实审计显示最终 decision 为 warn 后放行：Gate4 会递归扫描参数 中的字面字符串，但不会把结构化 sources 中的符号型引用解析到 OAR 业务世界并查询所指资产的敏感级别；模型只携带引用而正文保持干净。该结果在冻结后 未通过改 payload 或重跑来掩盖。D2 则提供了同一不可变 ToolIntent 在 Null 产生 harm、XA-Guard deny 且不产生 harm 的因果证明。脱敏证据与 authenticity 复核见 docs/evidence/live-agent-holdout-v1-2026-07-27.md。

轨道 C：2026-07-11 OAR canonical full-day / replay

canonical full-day 完成 41 次工具尝试，产生 43 条 ledger 记录，ledger violation 为 0；该轨 7/7 次 attempt replay 均通过，XA-Guard 侧工具事件、range audit、ledger 和原始 Gate6 记录逐序对齐。这里的 7/7 属于 canonical 轨，不与轨道 A 的 20/20 合并，也不替代轨道 B 的 30-run 结果。

5.5 故障实验

Reference all-fault 将身份拒绝、授权撤销、租户隔离、数据库中断、API 崩溃恢复、并发审批、Worker 接管、持久化重试、错误 KEK、密钥轮换和历史记录恢复组合为 11 个场景，最终结果为 11/11。

故障实验同时检查业务有效副作用数量。例如并发审批和 Worker 重试可以产生多次调度尝试，但业务接口只能观察到一次有效取消。这使测试结果同时覆盖控制面状态和实际业务后果。

5.6 性能实验

每个性能样本由一次 XA-Guard 受保护写和一次直接业务写组成。AB/BA 顺序平衡并打乱，新增开销定义为：

```
incremental_latency =
protected_write_latency - direct_business_write_latency
```

实验使用 10 并发，每轮 30 次 warmup 和 500 次 measured pairs。除增量 p95 外，还通过 5000 次非参数 bootstrap 计算单侧 95% p95 上界。三轮结果如下：

seed	incremental p95	单侧 95% bootstrap upper
20260741	45.109ms	46.984ms
20365470	42.141ms	43.120ms
20470199	43.934ms	45.528ms

三轮点估计与上界均低于 50ms。相同实验中完成 10 次 Undo，批准到业务取消约为 0.45 至 0.94s。

5.7 代表性攻击链与业务后果验证

在 OAR 主评测之外，本文从赛题四个方向选取六类代表性攻击链，固化为可复现证明集（[xa-attack-proof-set-v1](#)）。证明集关注攻击是否跨越安全边界、是否触发下游动作以及业务状态是否改变，而不是仅判断一段输入是否包含恶意文本。每类攻击保留独立业务判据，结果按各自判据分别报告（口径见 § 5.9）。

以邮箱间接提示注入为例展开一条完整链：不可信内容随一封普通邮件进入邮箱场景；确定性 seat 读取邮件后形成越界外发意图；Null 侧发起对外发送，脱敏合成敏感引用被发往外部目标；同一 finding 在 XA-Guard 侧运行时，网关在工具执行前裁决为 deny，下游外发为 0，Gate6 记录与靶场 ledger、replay 结果逐序对齐。两侧各独立重复 10 次，结果一致。

最终证明运行 [xa-attack-proof-v1-20260727T033934Z-win-local](#) 在 clean checkout 上完成，运行起止 Git HEAD 均为 [6deacef266d2348e43ab7166b9aa39ca2cbc6cdb](#)，工作树均无未提交修改。封存包 SHA-256 为 [435d170585e2266a65107db1bba3ee2705b5cfec8b29d76948d59898026e8e5b](#)；根清单覆盖除自身外的 730/730 个文件，并包含 OAR 的 40 个子 hash 清单。

六类 case 的对照与业务观测如下：

赛题映射	代表性攻击链	对照设计	已观察业务结果
方向一：复杂输入链路	邮箱间接提示注入外发	Null / XA-Guard live 各 10 次	Null 泄漏 10/10；保护侧泄漏 0/10，infra error 0；10/10 protected replay 的 hash、ledger、SUT/原始 Gate6 对齐通过
方向一：复杂输入链路	RAG 间接提示注入外发	Null / XA-Guard live 各 10 次	Null 泄漏 10/10；保护侧泄漏 0/10，infra error 0；10/10 protected replay 的 hash、ledger、SUT/原始 Gate6 对齐通过

赛题映射	代表性攻击链	对照设计	已观察业务结果
方向二：工具与任务执行	未经批准的高风险命令	Null、拒绝、批准三路	Null 下游 1；拒绝下游 0，审计 require_approval → deny；批准对照下游 1，审计 require_approval → allow
方向三：供应链安全	恶意插件准入	恶意 code snippet 与本地干净 artifact	恶意插件 deny、下游 0；干净 artifact 经批准后 require_approval → allow、下游 1
方向四：评测与审计	Gate6 审计副本篡改	clean 与 tampered 副本	clean 验签通过，tampered 验签失败，原始 audit hash 不变
横向身份边界	伪造 header、撤权与跨租户隔离	独立验签最终 identity evidence bundle	verifier 通过；14 artifacts / 102 Effect / 59 Gate6，三个身份 subcase 均满足预设判据

该证明集为合成确定性场景，不包含真实模型决策；结果适用于本场景与上述对照设计，其实验边界与脱敏口径集中见 § 5.9。真实 Agent 结果以 § 5.4 轨道 B 为准，不能用本节的 0/10 替代。公开复现材料由脱敏 case manifest、评测 runner、结果摘要、源码 provenance 和文件 hash 组成，见 <docs/evidence/attack-proof-set-2026-07-27-n10.md>。

5.8 证据完整性

最终 evidence 从同一候选环境采集，包含身份、assignment、业务对象、Undo 请求、Effect 链、Gate6 链和三份验收报告。Collector 执行 secret scan、hash 重算、链间引用检查和业务状态断言，随后生成签名 manifest。独立 verifier 固定 public key id 并验证 14 个 artifacts、102 条 Effect 和 59 条 Gate6 记录。

真实 Agent holdout 另由离线 authenticity verifier 复核：303 个文件 hash 一致，冻结 manifest 自哈希一致，summary 指标可精确重算，15 条真实 XA-Guard audit 均与不可变 ToolIntent 的工具、参数 hash、decision 和 record hash 对齐，20/20 项检查通过。脱敏摘要不包含原始注入文本、模型 transcript、生产凭据或绝对路径。

5.9 能力边界与不声明事项

本节集中列出全文结果的适用边界与不声明事项，正文各处的指标与结论均以本节口径为准。

识别指标边界

- Gate1 识别指标只在以下边界内成立：第一，60 例规模较小，仅覆盖 § 5.2 的 6 个输入攻击族；第二，seed 与规则开发同源，[independent_holdout=false](#)，payload 指纹切分是诊断性切分，不是独立泛化评估；第三，误报结果必须与 Wilson 区间一起报告，不能只报告 0.0 点值；第四，0.02/0.04ms 是规则层延迟，不包含模型后端推理、完整网关链路或下游工具时延；当前封存 Gate1 数字来自 rule detector 口径，不能归因于可选模型后端。

- 指标体系不把不同风险合并为单一总分；预期效果是在声明范围内降低真实业务后果，而不是只给出文本分类分数。

策略判定边界

- Gate3 单条 predicate 运行期异常按未命中处理（口径同 § 3.3 表与 § 3.4），不宣称全局 fail-closed。

证明集与实验边界

- 确定性证明集（§ 5.4 轨道 A、§ 5.7）不运行真实模型：OAR live A/B 每类每侧 N=10，只说明给定同一合成 finding 时的业务因果结果，不外推为真实 Agent 攻击率或泛化攻击率。其保护侧 replay 为两类合计 20/20；canonical full-day 的 7/7 replay 属于另一封存轨道，二者不相加。
- MCP 下游为只记账的安全合成 target，不执行命令、插件或网络动作。
- 身份边界 case 复用独立验签的最终 evidence bundle，不重跑长故障套件。
- 每类攻击保留独立业务判据，证明集不把异构指标合并成单一攻击成功率。

- D1 正文不复制原始注入 payload、危险命令、插件攻击代码、原始审计记录、审批令牌或运行环境绝对路径，避免把攻击文本的新颖性误写成系统防护能力。

真实 Agent 边界

- 真实 Agent holdout（§ 5.4 轨道 B）只有 3 个冻结合成 case、2 个提示档、每格 5 次，共 30 runs；使用单一 DeepSeek V4 Pro、temperature 0、thinking disabled。它是小规模冻结 holdout，不是独立第三方 benchmark，也不代表所有模型、提示、工具或政企业务。
- D2 两档合计 10/10 attempt、Null harm 10/10、XA-Guard deny 10/10/harm 0/10，是当前真实 Agent 轨的有效因果阻断证据；D1 realistic-safe 的 5/5 attempt 与 XA-Guard allow/harm 5/5 是同等有效的 未覆盖结果，根因边界为结构化 [sources](#) 引用没有被解引用并映射到业务资产敏感级别。本文不把它隐藏在 确定性 RAG 证明集的 0/10 后面。
- D1 neutral-tool 的 0/5 与 D3 两档合计 0/10 都表示模型没有产生违规 ToolIntent；Guard 分支未执行，因此不得记为 XA-Guard 阻断成功。汇总 ASR 只用于这 30-run 冻结设计内部，不与 Gate1 或确定性 OAR 合并。
- 30 个 run 的 [infra_status](#) 均为 ok，summary 记 [infra_failures=0](#)；评测包装进程在证据完整落盘后的 MCP teardown 返回过非零退出码但无 Traceback，authenticity 仍 20/20 通过。本文据逐 run 状态报告 infra 0，同时把 teardown 返回码保留为待定位的 harness 边界。

兼容与部署边界

- § 6.2 的结果证明 MCP/HTTP 网关契约可被真实客户端触发，不等同于 OpenClaw 官方 SDK 或专有接口已经完成适配，也不外推为所有国产 IDE 的原生 HITL 弹窗均已跑通。
- 落实合规要求时，实际部署仍需结合组织制度、目标系统定级、密码应用方案和正式测评流程（§ 6.4）。
- 进入组织生产环境还需要完成目标 IdP、TLS、托管数据库、正式 KMS/HSM、备份、监控和容量验证（§ 7）。

证据公开边界

- 公开证据只包含审计投影和摘要，访问令牌、恢复材料和私钥保留在运行环境（§ 3.7）。
- 真实 Agent 脱敏摘要不含原始 holdout payload、原始 transcript、外发正文、生产地址或绝对路径；只公开实验身份、聚合计数、边界说明、根文件 SHA-256 与 verifier 结果。

6. 政企应用价值

6.1 对业务系统的接入方式

XA-Guard 采用网关方式接入。支持 MCP 的客户端可以把工具调用先发送到 XA-Guard；传统业务应用可以使用 Control API。模型、客户端和业务接口之间保持松耦合，安全策略、审批和证据由网关集中处理。

动态授权关系适合组织中的“人员-数字员工-数据域”管理。人员离岗、岗位变化或智能体能力调整时，管理员修改 assignment 即可生效。YAML ceiling 保留平台级安全底线，业务部门的 overlay 负责表达部门和场景差异。

6.2 兼容 OpenClaw 类智能体

赛题要求兼容 OpenClaw 类智能体及其他具备工具调用能力的大模型应用。XA-Guard 将兼容边界放在工具调用协议层，而不是绑定某个基座模型或客户端插件：上游只要能把工具名、参数、身份上下文和目标数据域经 MCP stdio、Streamable HTTP 或 Control API 交给网关，就能复用同一套六关治理、Effect 持久化和 Gate6 审计；下游业务工具不需要感知调用来自哪一种智能体客户端。

当前实测范围包括 Claude Code 的本地 MCP Server 注册与握手、独立 stdio JSON-RPC harness 的 9 个真实 MCP 场景，以及两条 OpenCode Streamable HTTP 轨道。2026-06-18 轨道验证 OpenCode 1.17.8 / GLM-5.2 的真实模型选工具与 pending approval fallback；2026-07-27 又在隔离配置中用 OpenCode 1.18.5 / DeepSeek V4 Flash 完成工具发现、一次无副作用 `get_cpu` 调用和 Gate6 审计验签，1 条记录、0 error。对未声明 elicitation 能力的客户端，系统已验证 pending approval 与控制工具 fallback；支持 elicitation 的客户端可使用协议内交互审批。上述结果表明 MCP/HTTP 网关契约可在真实客户端上触发，其兼容范围与不声明事项见 § 5.9。若发榜方另行给出 OpenClaw 专有接口规范，可在现有契约外增加薄适配层，而不改变核心治理链。

6.3 对安全与审计工作的价值

安全团队能够从同一条记录中看到人员、智能体、工具、数据域、策略版本、审批人、业务引用和结果。Effect 把审计与恢复连接起来：审计人员不仅能定位异常写操作，还能看到可逆性、恢复窗口、补偿状态和失败原因。

OAR 提供从攻击任务到业务后果的可重复验证方法。策略调整后可以重跑相同 finding 和 replay，比较保护效果及审计变化，从而形成评测、修复和复验闭环。

6.4 与合规和治理要求的衔接

GB/T 45654-2025 对生成式人工智能服务的安全要求、GB/T 22239-2019 的身份鉴别与安全审计、GB/T 39786-2021 的密码应用要求，为政企智能体治理提供了基础规范[10-12]。《人工智能安全治理框架》2.0 强调风险分类、全生命周期治理和技管结合[13]。OWASP 针对 LLM 与 Agentic Application 总结了提示注入、过度代理、工具滥用和身份权限等风险[14-15]；NIST AI 600-1 则从治理、测量和风险管理角度给出生成式人工智能的组织级实践框架[16]。

XA-Guard 中的身份验证、最小权限、运行时控制、审批、密码完整性、评测和恢复机制可以为组织落实相关要求提供技术支撑。实际部署的配套条件见 § 5.9。

6.5 与既有方案的横向对比

下表按赛题关注的行动链能力比较公开资料中可核验的范围。外部方案标注“未核验”仅表示本次事实源未提供该能力的直接证据，该标注本身不断言产品或研究工作是否具备该能力；不同方案的公开指标、硬件、数据集和任务定义口径各异，表中按各自公开范围定性列出，不做数值横比[3,17-20]。

方案	输入检测	工具授权	信息流	供应链	副作用恢复	证据链
Lakera Guard	官方披露检测率 >98%、FPR <0.5%[17]	未核验人员-智能体动态授权或 HITL	未核验跨工具信息流	未核验 AIBOM 准入	未核验恢复合同	未核验运行审计哈希链
Meta Llama Firewall	PromptGuard 2.86M: 97.5% Recall @ 1% FPR; 另含 AlignmentCheck[18]	未核验企业身份授权或审批	未核验跨工具污点传播	CodeShield 做代码扫描，不等同于插件准入	未核验业务副作用恢复	未核验运行审计双链
CaMeL	以系统设计防提示注入，不以输入分类器为核心	未核验政企身份与 HITL	控制流/数据流分离; AgentDojo 77% provable-secure completion[3]	未核验组件准入	未核验业务副作用恢复	未核验运行审计链
AgentSpec	trigger/predicate 规则，不是输入检测产品	DSL 约束 trigger、predicate 与 enforcement[19]	未核验跨工具信息流	未核验组件准入	未核验业务副作用恢复	未核验运行审计链
ShieldAgent	概率规则电路，不是输入检测产品	以可验证规则电路约束策略推理[20]	未核验跨工具信息流	未核验组件准入	未核验业务副作用恢复	形式化验证不等同于运行期审计证据
XA-Guard	Gate1 规则/模型接口、Spotlighting 与分层指标	动态 assignment、Gate2/3、HITL、deny 优先	Gate4 来源标签、敏感字段与出向控制	AIBOM、CycloneDX、A/B/C/D/F 五档与可选验签	intent-first Effect、恢复合同、职责分离 Undo、Worker 补偿	Effect/Gate6 双链、交叉引用、SM2-with-SM3 manifest 与篡改对照

在这组选定对象及已核验公开范围内，XA-Guard 的差异点不是单独提高输入分类分数，而是把执行前授权、信息流、供应链准入、真实副作用恢复和可独立验签证据放入同一运行时闭环。其中“副作用恢复”和“Effect/Gate6 双链可验签证据”是本项目直接实现并以业务状态 oracle 验证的能力。

7. 结论

XA-Guard 将智能体安全从输入过滤扩展到完整行动链。人员-智能体双主体身份解决可信委托问题；六网关在工具执行前后统一处理输入、审批、策略、信息流、隔离和审计；intent-first Effect 把副作用恢复所需的信息提前到执行之前；AIBOM 控制扩展组件入口；OAR 和签名 evidence 用于验证防护结果与审计完整性。

项目已经完成跨身份服务、网关、数据库、业务接口、Worker、Console 和评测环境的工程闭环。最终候选通过故障、并发性能、本地集群和统一质量验证，并保留可独立验签的证据包。

实验结论按轨道成立：确定性 OAR N=10 证明集给出两类 finding 的 Null 泄漏 20/20、XA-Guard 泄漏 0/20 与保护侧 replay 20/20；canonical full-day/replay 独立报告为 41 次工具尝试、43 条 ledger、0 violation 和 7/7 replay。真实 DeepSeek Agent 冻结 holdout 则在 30 runs、infra 0 下同时得到 D2 的 10/10 因果阻断和 D1 sources 引用型外发的 5/5 allow/harm 未覆盖边界，D3 的 0/10 attempt 只归因模型侧安全。该结果说明现有运行时治理链能够约束一类真实高风险动作，也明确把结构化引用解析和敏感资产查询列为下一项防护重点。

本文实验基于 Reference Compose、本地三节点 kind 与小规模冻结合成 holdout，结论适用于当前实现、模型、场景与恢复合同，不声明对未知攻击或所有 OpenClaw 类客户端的完全覆盖；进入组织生产环境的前置条件与全部不声明事项见 § 5.9。

参考文献

- [1] Debenedetti E, Zhang J, Balunovic M, et al. AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents[C]//Advances in Neural Information Processing Systems. 2024. <https://proceedings.neurips.cc/paper_files/paper/2024/hash/97091a5177d8dc64b1da8bf3e1f6fb54-Abstract-Datasets_and_Benchmarks_Track.html>
- [2] Zhan Q, Liang Z, Ying Z, et al. InjecAgent: Benchmarking Indirect Prompt Injections in Tool-Integrated Large Language Model Agents[C]//Findings of the Association for Computational Linguistics: ACL 2024. 2024: 10471-10506. <<https://aclanthology.org/2024.findings-acl.624/>>
- [3] Debenedetti E, Shumailov I, Fan T, et al. Defeating Prompt Injections by Design[EB/OL]. arXiv:2503.18813, 2025. <<https://arxiv.org/abs/2503.18813>>
- [4] Wu Y, Roesner F, Kohno T, et al. IsolateGPT: An Execution Isolation Architecture for LLM-Based Agentic Systems[C]//Network and Distributed System Security Symposium. 2025. <<https://doi.org/10.14722/ndss.2025.241131>>
- [5] Sakimura N, Bradley J, Agarwal N. RFC 7636: Proof Key for Code Exchange by OAuth Public Clients[S]. IETF, 2015. <<https://www.rfc-editor.org/rfc/rfc7636>>
- [6] Jones M, Nadalin A, Campbell B, et al. RFC 8693: OAuth 2.0 Token Exchange[S]. IETF, 2020. <<https://www.rfc-editor.org/rfc/rfc8693>>
- [7] Lodderstedt T, Bradley J, Labunets A, et al. RFC 9700: Best Current Practice for OAuth 2.0 Security[S]. IETF, 2025. <<https://www.rfc-editor.org/rfc/rfc9700>>
- [8] Model Context Protocol. Authorization Specification, Version 2025-11-25[EB/OL]. 2025. <<https://modelcontextprotocol.io/specification/2025-11-25/basic/authorization>>
- [9] Ecma International. ECMA-424: CycloneDX Bill of Materials Standard, 1st Edition[S]. 2024. <<https://ecma-international.org/publications-and-standards/standards/ecma-424/>>
- [10] 国家市场监督管理总局, 国家标准化管理委员会. GB/T 45654-2025 网络安全技术 生成式人工智能服务安全基本要求[S]. 2025. <<https://openstd.samr.gov.cn/bzgk/std/newGblInfo?hcnno=F67D3F376E0A0A0FF5317FB36B32A30A>>
- [11] 国家市场监督管理总局, 国家标准化管理委员会. GB/T 22239-2019 信息安全技术 网络安全等级保护基本要求[S]. 2019. <<https://openstd.samr.gov.cn/bzgk/std/newGblInfo?hcnno=BAFB47E8874764186BDB7865E8344DAF>>
- [12] 国家市场监督管理总局, 国家标准化管理委员会. GB/T 39786-2021 信息安全技术 信息系统密码应用基本要求[S]. 2021. <<https://openstd.samr.gov.cn/bzgk/std/newGblInfo?hcnno=53282C88712CE157043B7A2C590278FC>>
- [13] 国家互联网应急中心牵头组织有关专业机构、科研院所和行业企业（国家互联网信息办公室指导）。人工智能安全治理框架 2.0[R]. 2025. <https://www.cac.gov.cn/2025-09/15/c_1759653448369123.htm>
- [14] OWASP GenAI Security Project. OWASP Top 10 for LLM Applications 2025[R]. 2025. <<https://genai.owasp.org/llm-top-10/>>
- [15] OWASP GenAI Security Project. OWASP Top 10 for Agentic Applications 2026[R]. 2025. <<https://genai.owasp.org/resource/owasp-top-10-for-agentic-applications-for-2026/>>
- [16] Autio C, Schwartz R, Dunietz J, et al. Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile, NIST AI 600-1[R]. National Institute of Standards and Technology, 2024. <<https://doi.org/10.6028/NIST.AI.600-1>>
- [17] Check Point Software Technologies. Check Point Acquires Lakera to Deliver End-to-End AI Security for Enterprises[EB/OL]. 2025. <<https://www.checkpoint.com/press-releases/check-point-acquires-lakera-to-deliver-end-to-end-ai-security-for-enterprises/>>
- [18] Meta. LlamaFirewall: An open source guardrail system for building secure AI agents[EB/OL]. 2025. URL: <https://meta-llama.github.io/PurpleLlama/LlamaFirewall/>

- [19] Wang Y, et al. AgentSpec: Customizable Runtime Enforcement for Safe and Reliable LLM Agents[EB/OL]. arXiv:2503.18666, 2025.
<<https://arxiv.org/abs/2503.18666>>
- [20] Zhang Y, et al. ShieldAgent: Shielding Agents via Verifiable Safety Policy Reasoning[EB/OL]. arXiv:2503.22738, 2025.
<<https://arxiv.org/abs/2503.22738>>

附录 A：验证材料索引

本附录单列本文结果对应的仓库验证记录，与学术论文、协议和标准分开。

验证内容	材料位置
Gate1 分层召回、误报、Wilson 区间与规则层时延	docs/evidence/gate1-l3-evaluation-2026-06-18.json
OAR canonical full-day 与 7/7 replay (2026-07-11 轨)	docs/acceptance/EVIDENCE-CONSOLIDATION.md § 2
确定性 OAR N=10 两类 finding 与保护侧 20/20 replay (2026-07-27 轨)	docs/evidence/attack-proof-set-2026-07-27-n10.md
真实 DeepSeek Agent 冻结 holdout: 30 runs、infra 0、D2 因果阻断与 D1 引用型外发边界	docs/evidence/live-agent-holdout-v1-2026-07-27.md
Reference 11/11 fault	docs/evidence/agent-identity-undo-final-2026-07-21/acceptance/reference-faults-all-final-rerun-20260721.json
本地三节点 kind	docs/evidence/agent-identity-undo-final-2026-07-21/acceptance/kind-ha-final-pass-20260721.json
正式 3×500 性能与 Undo	docs/evidence/agent-identity-undo-final-2026-07-21/acceptance/perf-formal-mixed-transaction-rebuilt-20260721.json
最终签名 evidence	docs/evidence/agent-identity-undo-final-2026-07-21.md
三账号 Console 闭环	docs/evidence/mcp-live-acceptance-2026-07-19/
Claude Code MCP 握手与 9 个 stdio JSON-RPC 场景	docs/evidence/mcp-live-acceptance-2026-07-19/
OpenCode Streamable HTTP 与 pending approval fallback	docs/evidence/l3-opencode-http-2026-06-18.md 、 docs/evidence/l3-hitl-pending-approval-2026-06-18.md
OpenCode 1.18.5 + DeepSeek V4 Flash 安全工具调用与 Gate6 验签	docs/evidence/d3-opencode-deepseek-flash-preflight-2026-07-27.md
最终仓库状态与统一验证	status.md